ВикипедиЯ

Алгоритм Ахо — Корасик

Материал из Википедии — свободной энциклопедии

Алгоритм Ахо — Корасик — алгоритм поиска подстроки, разработанный Альфредом Ахо и Маргарет Корасик в 1975 году[1], реализует поиск множества подстрок из словаря в данной строке.

Широко применяется в системном программном обеспечении, например, используется в утилите поиска grep[2]. Одно из показательных применений — антивирусы: вирусная база может занимать сотни мегабайт, однако разница в скорости между 2- и 200-мегабайтной базой совсем невелика.

Принцип работы

Алгоритм строит конечный автомат, которому затем передаёт строку поиска. Автомат получает по очереди все символы строки и переходит по соответствующим рёбрам. Если автомат пришёл в конечное состояние, соответствующая строка словаря присутствует в строке поиска.

Несколько строк поиска можно объединить в дерево поиска, так называемый бор (префиксное дерево). Бор является конечным автоматом, распознающим одну строку из m — но при условии, что начало строки известно.

Первая задача в алгоритме — научить автомат «самовосстанавливаться», если подстрока не совпала. При этом перевод автомата в начальное состояние при любой неподходящей букве не подходит, так как это может привести к пропуску подстроки (например, при поиске строки **aabab**, попадается aa**aabab**, после считывания пятого символа перевод автомата в исходное состояние приведёт к пропуску подстроки — верно было бы перейти в состояние a, а потом снова обработать пятый символ). Чтобы автомат самовосстанавливался, к нему добавляются суффиксные ссылки, нагруженные пустым символом ⌀ (так что детерминированный автомат превращается в недетерминированный). Например, если разобрана строка aaba, то бору предлагаются суффиксы aba, ba, a. Суффиксная ссылка — это ссылка на узел, соответствующий самому длинному суффиксу, который не заводит бор в тупик (в данном случае a).

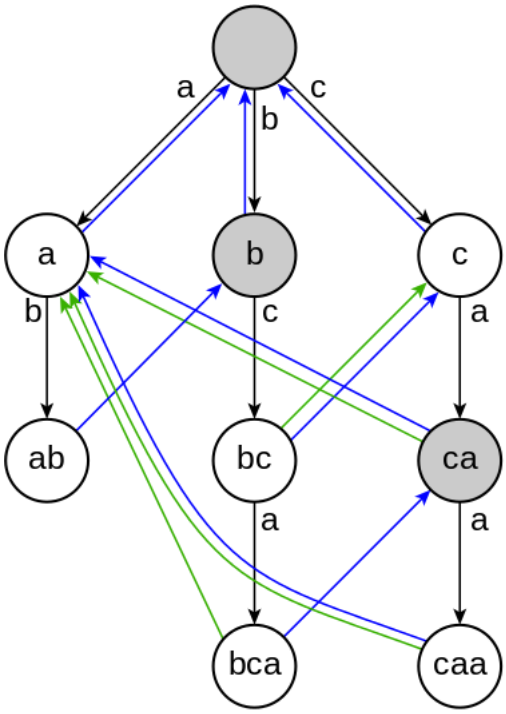

Недетерминированный автомат для словаря {a, ab, bc, bca, c, caa}. Серые вершины промежуточные, белые конечные. Синие стрелки — суффиксные ссылки, зелёные — конечные.

Для корневого узла суффиксная ссылка — петля. Для остальных правило таково: если последний распознанный символ — c, то осуществляется обход по суффиксной ссылке родителя, если оттуда есть дуга, нагруженная символом c, суффиксная ссылка направляется в тот узел, куда эта дуга ведёт. Иначе — алгоритм проходит по суффиксной ссылке ещё и ещё раз, пока либо не пройдёт по корневой ссылке-петле, либо не найдёт дугу, нагруженную символом c.

```
* ···⌀···> * ···⌀···> * ···⌀···> *
|                                 |
```

```
c                              c
↓                              ↓
[*] ·············ø·············> *
    новая суффиксная ссылка
```

Этот автомат недетерминированный. Преобразование недетерминированного конечного автомата в детерминированный в общем случае приводит к значительному увеличению количества вершин. Но этот автомат можно превратить в детерминированный, не создавая новых вершин: если для вершины v некуда идти по символу c, проходимся по суффиксной ссылке ещё и ещё раз — пока либо не попадём в корень, либо будет куда идти по символу c.

Всю детерминизацию удобно делать рекурсивно. Например, для суффиксной ссылки:

```
алг СуффСсылка(v)
  если v.кэшСуффСсылка ≠ ∅      // для корня изначально корень.кэшСуффСсылка = корень
    вернуть v.кэшСуффСсылка
  u := v.родитель
  c := v.символ
  повторять
    u := СуффСсылка(u)
  до (u = корень) или (существует путь u —c→ w)
  если существует переход u —c→ w
    то v.кэшСуффСсылка := w
    иначе v.кэшСуффСсылка := корень
  вернуть v.кэшСуффСсылка
```

Детерминизация увеличивает количество конечных вершин: если суффиксные ссылки из вершины v ведут в конечную u, сама v тоже объявляется конечной. Для этого создаются так называемые конечные ссылки: конечная ссылка ведёт на ближайшую по суффиксным ссылкам конечную вершину; обход по конечным ссылкам даёт все совпавшие строки.

```
алг ВывестиРезультат(v, i)
  напечатать "Найдено " + v.иголка + " в позиции " + (i - v.глубина + 1)
```

```
алг ОсновнаяЧастьПоиска
  состояние := корень
  цикл i=1..|стогСена|
    состояние := Переход(состояние, стогСена[i]);
    если состояние.иголка ≠ ∅
      ВывестиРезультат(состояние, i)
    времСост := состояние
    пока КонечнаяСсылка(времСост) ≠ ∅
      времСост := КонечнаяСсылка(времСост);
      ВывестиРезультат(времСост, i)
```

Суффиксные и конечные ссылки в автомате можно рассчитывать по мере надобности уже на фазе поиска. Побочные переходы — можно вычислять на месте, никак не кэшируя, можно кэшировать для всех узлов, можно — для важнейших (на асимптотическую оценку алгоритма всё это не влияет).

Вычислительная сложность

Вычислительная сложность работы алгоритма зависит от организации данных. Например:

- Если таблицу переходов автомата хранить как индексный массив — расход памяти $O(n\sigma)$, вычислительная сложность $O(n\sigma + H + k)$, где H — длина текста, в котором производится поиск, n — общая длина всех слов в словаре, σ — размер алфавита, k — общая длина всех совпадений.
- Если таблицу переходов автомата хранить как красно-чёрное дерево — расход памяти снижается до $O(n)$, однако вычислительная сложность поднимается до $O((H + n)\log\sigma + k)$.

Примечания

1. *Alfred V. Aho, Margaret J. Corasick.* Efficient string matching: An aid to bibliographic search // Communications of the ACM. — 1975. — Т. 18, № 6. — С. 333—340. — DOI:10.1145/360825.360855 (https://dx.doi.org/10.1145%2F360825.360855).
2. grep-2.26 released [stable (https://www.mail-archive.com/info-gnu@gnu.org/msg02191.html)]. www.mail-archive.com. Проверено 4 октября 2016.